

Prédiction du défaut de remboursement d'un prêt immobilier (mortgage)

Plan :

1- Introduction et présentation de la problématique

- Contexte et problème métier
- Traduction en tâche ML
- État de l'art (étude bibliographique)
- Dataset

2- Analyse exploratoire des données EDA

- Aperçu général du dataset
- Valeurs manquantes
- Distribution des variables numériques
- Valeurs Aberrantes
- Analyse bivariée Variables catégorielles
- Corrélation
- Conclusion

3- Pré-processing des données

- Traitement valeurs manquantes
- Traitement des Outliers
- Encodage
- Normalisation
- Features Selection

4- Construction des modèles ML

5- Tuning et choix du modèle final

6- Déploiement

7- Conclusion

1-Introduction :

Dans le secteur financier, la gestion du risque de crédit est un enjeu important pour les établissements de prêt. Lorsqu'une banque accorde un prêt immobilier, elle doit être en mesure d'évaluer le risque de défaut de l'emprunteur afin de limiter les pertes financières potentielles. En effet, un défaut de paiement peut avoir un impact direct sur la rentabilité de la banque et nécessiter la mobilisation de capitaux supplémentaires.

L'évaluation du risque de crédit a longtemps reposé sur des règles métier et des modèles statistiques traditionnels. Avec l'augmentation du volume de données disponibles et les avancées technologiques, les méthodes de Machine Learning sont aujourd'hui largement utilisées pour améliorer la prédiction du risque de défaut.

Ces techniques permettent d'exploiter un grand nombre de variables et d'obtenir des résultats plus précis pour l'aide à la décision. C'est dans cette optique que se pose la question centrale de ce travail : comment prédire, à partir des caractéristiques d'un emprunteur et de son prêt, s'il sera en défaut de paiement ?

Plusieurs articles ont été publiés en ce sens et sur différentes bases de données, [Krasovytskyi et Stavytskyi \(2024\)](#) ont appliqué plusieurs algorithmes de Machine Learning pour prédire le défaut de remboursement de prêts immobiliers sur des données du registre de crédit ukrainien. Leur étude compare Random Forest, XGBoost, SVM, régression logistique, réseaux de neurones et analyse discriminante linéaire. Afin de gérer le déséquilibre entre les classes, les auteurs ont testé deux techniques : la pondération des données et SMOTE. En utilisant 7 variables (revenu annuel, ratio dette/revenu, âge, taux d'intérêt, risque crédit, maturité résiduelle et croissance du PIB), leurs résultats montrent que Random Forest et XGBoost offrent les meilleures performances avec un F1-score de 0.89 et 0.90 respectivement, surpassant significativement la régression logistique. Dans le même sens, [Akindaini \(2017\)](#) a appliqué cinq algorithmes de Machine Learning sur le dataset Fannie Mae pour classer les prêts en trois catégories : défaut, remboursement normal et remboursement anticipé. Les modèles testés sont la régression logistique, Naive Bayes, Random Forest et KNN, mais le Random Forest a présenté les meilleures performances avec une accuracy de 95,68 %. L'analyse des variables montre que l'âge du prêt est le facteur le plus déterminant. Une autre étude de [Barbaglia et al. \(2023\)](#) a analysé 12 millions de crédits immobiliers européens pour comparer des modèles de Machine Learning (XGBoost, Gradient Boosting, Random Forest) à la régression logistique traditionnelle. Les résultats montrent que XGBoost obtient les meilleures performances et que le ratio LTV et le taux d'intérêt courant jouent un rôle déterminant dans la prédiction du risque de crédit.

Ces travaux confirment la pertinence des algorithmes de Random Forest pour ce type de problème. Dans le cadre de ce projet, nous avons adopté une approche similaire, en testant 11 algorithmes de classification sur un dataset de 148 670 prêts, afin d'identifier le modèle le plus performant pour la prédiction du défaut de paiement.

Ce dataset, issu de la plateforme Kaggle, comprend 148 670 observations et 34 variables décrivant les caractéristiques des emprunteurs et de leurs prêts, dont une variable cible binaire « Status » indiquant si le client est en défaut de paiement ou non.

Description des variables :

Variables	Description
ID	Identifiant de la demande de prêt du client
year	Année de la demande de prêt
loan_limit	Indique si le prêt est conforme (<i>cf</i>) ou non conforme (<i>ncf</i>) aux plafonds réglementaires
Gender	Genre du demandeur (<i>homme, femme, conjoint, non renseigné</i>)
approv_in_adv	Indique si le prêt a été approuvé en avance (<i>pré-approuvé ou non</i>)
loan_type	Type de prêt (<i>type1, type2, type3</i>)
loan_purpose	Objet du prêt (<i>p1, p2, p3, p4</i>)
Credit_Worthiness	Niveau de solvabilité du demandeur (<i>l1, l2</i>)
open_credit	Indique si le demandeur possède des lignes de crédit ouvertes
business_or_commercial	Indique si le prêt est à usage professionnel/commercial ou personnel
loan_amount	Montant emprunté
rate_of_interest	Taux d'intérêt appliqué au prêt
Interest_rate_spread	Écart entre le taux d'intérêt du prêt et un taux de référence
Upfront_charges	Frais initiaux liés à l'obtention du prêt
Term	Durée du prêt en mois
Neg_ammortization	Indique si le prêt autorise un amortissement négatif
interest_only	Indique si le prêt propose une option de remboursement des intérêts uniquement
lump_sum_payment	Indique si un paiement forfaitaire est exigé à l'échéance du prêt
property_value	Valeur du bien immobilier financé
construction_type	Type de construction (<i>maison construite sur site ou maison préfabriquée</i>)
occupancy_type	Type d'occupation (<i>résidence principale, secondaire ou bien locatif</i>)
Secured_by	Type de garantie adossée au prêt (<i>bien immobilier ou terrain</i>)
total_units	Nombre de logements dans le bien financé
income	Revenu annuel du demandeur
credit_type	Bureau de crédit ayant évalué le demandeur (<i>CIB, CRIF, Experian, Equifax</i>)
Credit_Score	Score de crédit du demandeur
co-applicant_credit_type	Bureau de crédit du co-demandeur (<i>CIB, Experian</i>)
age	Âge du demandeur
submission_of_application	Mode de soumission de la demande (<i>directement à l'établissement ou non</i>)
LTV	Ratio prêt/valeur — montant emprunté divisé par la valeur du bien

Region	Région géographique du bien (<i>Nord, Sud, Centre, Nord-Est</i>)
Security_Type	Type de sûreté garantissant le prêt (<i>directe ou indirecte</i>)
Status	Variable cible — défaut de paiement (<i>1 = défaut, 0 = non défaut</i>)
Dtir1	Ratio dette/revenu du demandeur

2- Analyse exploratoire des données EDA

Aperçu général du dataset :

Le dataset contient 148 670 observations et 34 variables couvrant les caractéristiques démographiques, financières et contractuelles des emprunteurs.

#affichage
df.head()

	ID	year	loan_limit	Gender	approv_in_adv	loan_type	loan_purpose	Credit_Worthiness	open_credit	business_or_commercial	...	credit_type	Credit_Score	
0	24890	2019	cf	Sex Not Available	nopre	type1	p1	I1	nopc	nob/c	...	EXP	758	
1	24891	2019	cf	Male	nopre	type2	p1	I1	nopc	b/c	...	EQUI	552	
2	24892	2019	cf	Male	pre	type1	p1	I1	nopc	nob/c	...	EXP	834	
3	24893	2019	cf	Male	nopre	type1	p4	I1	nopc	nob/c	...	EXP	587	
4	24894	2019	cf	Joint	pre	type1	p1	I1	nopc	nob/c	...	CRIF	602	

5 rows × 34 columns

df.columns

Index(['ID', 'year', 'loan_limit', 'Gender', 'approv_in_adv', 'loan_type',
 'loan_purpose', 'Credit_Worthiness', 'open_credit',
 'business_or_commercial', 'loan_amount', 'rate_of_interest',
 'Interest_rate_spread', 'Upfront_charges', 'term', 'Neg_ammortization',
 'interest_only', 'lump_sum_payment', 'property_value',
 'construction_type', 'occupancy_type', 'Secured_by', 'total_units',
 'income', 'credit_type', 'Credit_Score', 'co-applicant_credit_type',
 'age', 'submission_of_application', 'LTV', 'Region', 'Security_Type',
 'Status', 'dtir1'],
 dtype='object')

df.shape

(148670, 34)


```
df.info()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 148670 entries, 0 to 148669
Data columns (total 34 columns):
#   Column                                Non-Null Count  Dtype
---  -
0   ID                                     148670 non-null  int64
1   year                                 148670 non-null  int64
2   loan_limit                           145326 non-null  object
3   Gender                               148670 non-null  object
4   approv_in_adv                        147762 non-null  object
5   loan_type                            148670 non-null  object
6   loan_purpose                           148536 non-null  object
7   Credit_Worthiness                    148670 non-null  object
8   open_credit                          148670 non-null  object
9   business_or_commercial               148670 non-null  object
10  loan_amount                          148670 non-null  int64
11  rate_of_interest                     112231 non-null  float64
12  Interest_rate_spread                 112031 non-null  float64
13  Upfront_charges                      109028 non-null  float64
14  term                                 148629 non-null  float64
15  Neg_ammortization                    148549 non-null  object
16  interest_only                        148670 non-null  object
17  lump_sum_payment                     148670 non-null  object
18  property_value                       133572 non-null  float64
19  construction_type                    148670 non-null  object
20  occupancy_type                       148670 non-null  object
21  Secured_by                           148670 non-null  object
22  total_units                           148670 non-null  object
23  income                               139520 non-null  float64
24  credit_type                          148670 non-null  object
25  Credit_Score                         148670 non-null  int64
26  co-applicant_credit_type              148670 non-null  object
27  age                                   148470 non-null  object
28  submission_of_application             148470 non-null  object
29  LTV                                   133572 non-null  float64
30  Region                               148670 non-null  object
31  Security_Type                        148670 non-null  object
32  Status                               148670 non-null  int64
33  dtirl                                 124549 non-null  float64
dtypes: float64(8), int64(5), object(21)
memory usage: 38.6+ MB
```

Variable cible :

La variable cible « **Status** » est binaire :


- 0 : remboursement normal → 112 031 cas (75.4%)
- 1 : défaut de paiement → 36 639 cas (24.6%)



Le dataset présente un déséquilibre modéré entre les classes, ce qui a été pris en compte lors du preprocessing via stratify=y dans le train/test split.

Valeurs manquantes :

Les variables de la base de données comprennent des valeurs manquantes comme l'illustre le graphe suivant :



Selon les pourcentages, trois groupes se distinguent :

- Upfront_charges, Interest_rate_spread et rate_of_interest: environ 25%
- dtir1, property_value et LTV: entre 10% et 16%
- Les autres variables : moins de 3%

Une analyse approfondie a révélé des observations importantes :

- Interest_rate_spread présente un data leakage parfait, ses valeurs manquantes coïncident exactement avec les cas de défaut (Status=1). Cette variable sera supprimée lors du preprocessing.
- rate_of_interest, age et submission_of_application présentent un risque de data leakage partiel. Les valeurs manquantes (NaN) apparaissent uniquement pour les observations où Status=1, tandis que cette même classe contient également des valeurs renseignées. Une imputation spécifique devra donc être mise en place.
- Les autres variables présentent des valeurs manquantes aléatoires réparties dans les deux classes ce qui implique une imputation standard.

Distribution des variables numériques :


L'analyse des histogrammes des variables numériques révèle les observations suivantes :


- **loan_amount, income, property_value** : distributions asymétriques à droite (skewed), avec une concentration des valeurs sur les faibles montants et quelques valeurs élevées. Cette

asymétrie est caractéristique des données financières. La majorité des emprunteurs ont des revenus modestes et quelques-uns ont des revenus très élevés.

- **rate_of_interest** : distribution proche de la normale, centrée autour de 4%.
- **dtir1** : distribution globalement symétrique et relativement proche d'une loi normale.
- **LTV** : forte concentration des valeurs vers la gauche, avec la présence de valeurs extrêmes qui écrasent la visualisation, ce qui suggère la présence d'outliers importants, confirmée par l'analyse des boxplots.





Les variables financières présentent des distributions non normales nécessitant une normalisation lors du preprocessing.






Valeurs Aberrantes :















L'analyse des boxplots révèle que la variable LTV présente de véritables outliers avec un maximum de 7831%, ce qui est incohérent pour un ratio prêt/valeur normalement compris entre 0 et 100%. Les variables loan_amount, property_value et income présentent des valeurs extrêmes mais légitimes d'un point de vue métier.






Analyse bivariée Variables catégorielles :

L'analyse du taux de défaut par modalité révèle plusieurs tendances importantes :





Variables très liées au défaut :


- Neg_ammortization : l'amortissement négatif est fortement associé au défaut, car le capital du prêt augmente au lieu de diminuer
- construction_type : les manufactured homes (MH) présentent davantage de défauts, ce qui s'explique par une valeur de garantie plus faible
- credit_type : le bureau EQUI est associé à un taux de défaut plus élevé
- age : Les tranches d'âge extrêmes (moins de 25 ans et plus de 74 ans) présentent les taux de défaut les plus élevés, revenus instables pour les jeunes et fixes pour les retraités.

Variables modérément liées au défaut :

- Region : la région North-East présente le taux de défaut le plus élevé
- occupancy_type : les résidences d'investissement (investment residences – IR) affichent plus de défauts
- loan_limit : les prêts non conformes (NCF) sont plus risqués

Les variables catégorielles sont globalement plus informatives que les variables numériques pour la prédiction du défaut. Cela oriente le choix vers des modèles capables de capturer des relations non linéaires entre les variables et notre variable cible « Status »

Corrélation :



Les corrélations avec Status sont toutes faibles (max -0.07 pour income), ce qui indique que les variables numériques seules ne suffisent pas à prédire le défaut. Les variables catégorielles semblent davantage liées au défaut d'après l'analyse bivariable.

Une forte corrélation est observée entre loan_amount et property_value (0.73), ce qui peut indiquer un risque de multicollinéarité entre ces deux variables.

rate_of_interest et Interest_rate_spread présentent également une corrélation élevée (0.61). Toutefois, Interest_rate_spread sera supprimée lors du preprocessing en raison du data leakage identifié.

Une corrélation modérée entre loan_amount et income (0.46) est observée, cette relation est logique d'un point de vue métier (revenu élevé = capacité d'emprunt plus importante) et ne constitue pas une multicollinéarité problématique.

Conclusion Générale EDA :

L'analyse exploratoire des données a permis de mettre en évidence plusieurs points importants pour la suite du projet :

- Les variables ID et year n'apportent pas d'information utile pour la prédiction du défaut. Elles seront donc supprimées lors du prétraitement.
- La variable Interest_rate_spread présente un problème de data leakage. Ses valeurs manquantes étant directement liées à la variable cible, elle sera également retirée de l'analyse.

- Plusieurs variables contiennent des valeurs manquantes et elles nécessitent une imputation.
- Les variables numériques montrent globalement une faible corrélation avec la variable cible (Status), ce qui ne suggère qu'aucune d'entre elles ne permet à elle seule d'expliquer le défaut de paiement.
- Les variables catégorielles semblent davantage discriminer les profils en défaut des profils non défaillants et devraient donc jouer un rôle important dans la modélisation.
- Le jeu de données présente un déséquilibre entre les classes. Ce point devra être pris en compte lors du prétraitement et de l'entraînement des modèles afin d'éviter un biais en faveur de la classe majoritaire.

3-Pré-processing des données

Suppression des variables non informatives :

Trois variables ont été supprimées :

- **ID** : identifiant unique de la ligne, sans valeur prédictive
- **year** : variance nulle (toutes les observations datent de 2019)
- **Interest_rate_spread** : data leakage parfait avec la variable cible

Traitement des valeurs manquantes :

Afin de traiter les données manquantes sans biaiser les distributions, deux approches ont été mises en place :

- Imputation ciblée (conditionnelle) : pour les variables `rate_of_interest`, `age` et `submission_of_application`, l'imputation a été réalisée uniquement sur les observations en situation de défaut (`Status = 1`). La médiane (pour les variables numériques) et le mode (pour les variables catégorielles) ont été calculés sur ce sous-ensemble, afin de conserver la structure statistique des profils à risque.
- Imputation globale (NaN aléatoires) : pour les autres valeurs manquantes considérées comme distribuées de façon aléatoire, une approche classique a été appliquée. Les variables quantitatives ont été imputées par la médiane et les variables qualitatives par le mode.

Traitement des outliers :

La variable LTV (Loan-to-Value) présentait des valeurs extrêmes susceptibles de perturber la stabilité des modèles. Elle a donc été bornée à l'aide de la méthode de l'écart interquartile (IQR). Les valeurs situées au-delà des bornes ont été ramenées aux seuils suivants :

- Seuil inférieur : 31.16 %
- Seuil supérieur : 116.86 %

Encodage des variables catégorielles (Encoding) :

Afin de rendre les données exploitables par les algorithmes de Machine Learning, les variables qualitatives ont été transformées en variables numériques selon leur nature :

- Label Encoding : appliqué à la variable `âge`, qui est une variable ordinale. Cette méthode permet de conserver l'ordre et la hiérarchie des modalités.
- One-Hot Encoding (encodage disjonctif complet) : appliqué aux autres variables catégorielles nominales afin d'éviter d'introduire une fausse relation d'ordre entre des modalités indépendantes.

Normalisation des données :


La normalisation des données été réalisée à l'aide de la méthode StandardScaler (centrage-réduction) sur l'ensemble des 8 variables numériques continues. Ce choix a été privilégié par rapport au Min-Max Scaling pour sa robustesse et sa capacité à mieux gérer l'impact des valeurs extrêmes résiduelles.

Feature Selection :

Pour optimiser les temps de calcul et limiter la dimension des données, une sélection de variables a été réalisée à l'aide de la méthode de l'information mutuelle (mutual_info_classif).

Cette méthode permet de mesurer la dépendance entre chaque variable et la variable cible, que la relation soit linéaire ou non. Elle présente l'avantage d'être non paramétrique et de fonctionner avec tout type de variables (numériques continues, binaires issues du One-Hot Encoding), contrairement au test Chi2 qui nécessite des valeurs strictement positives ou à l'ANOVA (f_classif) qui suppose une relation linéaire.

En fixant un seuil de 0.01, le jeu de données a été réduit de 62 à 34 variables explicatives retenues.



4-Construction des modèles ML :

Le dataset a été divisé en deux sous-ensembles :

- Ensemble d'entraînement : 80% soit 118 936 observations
- Ensemble de test : 20% soit 29 734 observations

Le paramètre stratify=y a été utilisé pour garantir que la proportion de défauts (24.6%) soit identique dans les deux ensembles.

Métriques d'évaluation :

Compte tenu du déséquilibre entre les classes, les métriques suivantes ont été privilégiées :

- F1-score (classe 1) : équilibre entre précision et rappel
- AUC-ROC : performance globale du modèle

L'accuracy seule n'est pas suffisante en cas de déséquilibre entre les classes.

Résultats des 11 modèles :

Modèle	F1 classe 1	AUC-ROC
LightGBM	0.9631	0.9970
Gradient Boosting	0.9635	0.9967
XGBoost	0.9594	0.9966
Random Forest	0.9608	0.9960
AdaBoost	0.9613	0.9956
Decision Tree	0.9637	0.9943
Extra Trees	0.8333	0.9792
Naive Bayes	0.6446	0.9777
KNN	0.7342	0.9088
Logistic Regression	0.6494	0.8504
SVM Linear	0.6544	0.8492

Les modèles à base d'arbres (Random Forest, LightGBM, XGBoost, Gradient Boosting, AdaBoost, Decision Tree) obtiennent les meilleures performances avec un AUC-ROC supérieur à 0.99 et un F1-score de 0.96. Les modèles linéaires (Régression Logistique, SVM) sont moins performants avec un AUC-ROC autour de 0.85.

5- Tuning et choix du modèle final

À l'issue de la phase d'entraînement initiale, les trois modèles les plus performants ont été retenus pour le tuning :

- Gradient Boosting (F1-Score Classe 1 : 0.964 | AUC-ROC : 0.997)
- LightGBM (F1-Score Classe 1: 0.963 | AUC-ROC: 0.997)
- Random Forest (F1-Score Classe 1 : 0.961 | AUC-ROC : 0.996)

Méthode de tuning :

La méthode RandomizedSearchCV a été utilisée pour l'optimisation des hyperparamètres. Elle repose sur une exploration aléatoire d'un ensemble de combinaisons possibles, ce qui permet de tester efficacement différentes configurations sans parcourir exhaustivement tout l'espace des paramètres.

Dans ce cadre, les réglages suivants ont été appliqués :

- 20 combinaisons testées
- Validation croisée à 5 folds
- Métrique d'optimisation : AUC-ROC

Cette méthode a été privilégiée par rapport à GridSearchCV, car elle permet de réduire significativement le temps de calcul tout en offrant de bonnes performances, ce qui est particulièrement adapté à un dataset de grande taille.

Résultats avant/après tuning :

Modèle	AUC-ROC avant	AUC-ROC après
LightGBM	0.9970	0.9970
Gradient Boosting	0.9967	0.9970
Random Forest	0.9960	0.9969

Le tuning n'a pas apporté de gains significatifs car les modèles étaient déjà très performants avec les paramètres par défaut, confirmant la bonne qualité du preprocessing effectué.

Choix du modèle final

Les trois modèles présentent des performances quasi identiques après tuning.

Le choix de Random Forest comme modèle final repose sur des critères métier :

- Robustesse : combine plusieurs arbres de décision, moins sensible au bruit
- Fiabilité : résultats stables et reproductibles
- Absence d'overfitting confirmée : Train AUC-ROC (0.9985) $\approx$ Test AUC-ROC (0.9969)
- Contexte bancaire où la confiance dans le modèle est primordiale

Résultats finaux du modèle

- AUC-ROC : 0.9969
- F1-score classe 1 : 0.96
- Recall classe 1 : 1.00
- Precision classe 1 : 0.93
- Accuracy : 0.98

6-Déploiement

Sérialisation du modèle

Le modèle Random Forest final ainsi que le scaler ont été sérialisés avec joblib :

- model_rf.pkl : modèle Random Forest
- scaler.pkl : StandardScaler pour la normalisation des variables numériques

Application Streamlit

Une application interactive a été développée permettant :

- La saisie des caractéristiques du prêt par l'utilisateur
- L'affichage des données saisies
- L'affichage de la prédiction (défaut ou remboursement normal)
- Le niveau de confiance (probabilité de défaut)

Déploiement sur Streamlit Cloud :

L'application est accessible publiquement à l'URL :

[🔗 https://projet-loan-default-rania.streamlit.app/](https://projet-loan-default-rania.streamlit.app/)

Aperçu du site :

Prédiction de Défaut de Prêt Immobilier

Informations sur le prêt

Frais initiaux (Upfront charges)	Limite du prêt
0,00 - +	cf ▼
Durée du prêt (mois)	Genre
360 - +	Male ▼
Valeur du bien (€)	Pré-approuvé
0,00 - +	pre ▼
Revenu annuel (€)	Type de prêt
0,00 - +	type1 ▼
LTV (%)	Solvabilité
0,00 - +	l1 ▼
Ratio dette/revenu	Crédit ouvert
0,00 - +	opc ▼

Dépôt GitHub

Le code source est disponible sur :

[🔗 https://github.com/Rania19999/projet-ML-LOAN-DEFAULT](https://github.com/Rania19999/projet-ML-LOAN-DEFAULT)

Publication de l'application en utilisant flask sur la plateforme railway :

[🔗 https://web-production-ca2ab.up.railway.app/predict](https://web-production-ca2ab.up.railway.app/predict)



Prédiction de Défaut de Prêt Immobilier

Frais initiaux (Upfront charges)

0

Durée du prêt (mois)

360

Valeur du bien (\$)

84000

Revenu annuel (\$)

540

LTV (%)

70

Ratio dette/revenu

0

Limite du prêt

cf

Genre

Male

Pré-approuvé

pre

Type de prêt

type1

Solvabilité

I1

Crédit ouvert

opc

Usage

Amortissement négatif

Type de sécurité

direct



Prédire

REMBOURSEMENT NORMAL PROBABLE
Probabilité de défaut : 26.9%

Conclusion :

Ce projet a permis de construire un pipeline complet de Machine Learning pour la prédiction du défaut de remboursement de prêt, depuis la compréhension du problème jusqu'au déploiement du modèle.

L'analyse exploratoire a mis en évidence plusieurs points importants, notamment un data leakage sur la variable Interest_rate_spread ainsi que la présence de valeurs extrêmes sur la variable LTV. Un preprocessing complet a été réalisé avec le traitement des valeurs manquantes, l'encodage des variables, la normalisation et la sélection de variables via l'information mutuelle.

Onze algorithmes de classification ont été testés et comparés. Les modèles basés sur les arbres ont obtenu de meilleures performances que les modèles linéaires. Le modèle Random Forest a été retenu comme modèle final pour sa robustesse et sa stabilité, avec un AUC-ROC de 0.997 et un F1-score de 0.96 sur la classe de défaut.

Le modèle a été déployé sous forme d'application interactive via Streamlit, permettant de prédire en temps réel le risque de défaut d'un emprunteur. En perspective, l'intégration de variables macroéconomiques et l'application de techniques de rééchantillonnage comme SMOTE pourraient améliorer davantage les performances du modèle.